國立中央大學資訊工程學系

資料壓縮期末報告

LZMA 壓縮已壓縮的圖片

梁中瀚

資工三

目錄

一、前言

Lzma 為 7z 壓縮格式所支援的壓縮演算法，而 7z 又是近期大多數人會使用到的壓縮工具，並且大多數人都是直接將檔案放到壓縮檔裡面壓縮，實際測試先將圖片壓縮一次後，再放到 lzma 壓縮，與只用一次圖片壓縮的方式比較，觀察其檔案的大小。

Lzma 是基於 lz77 的壓縮演算法，並且結合 range coding(類似 arithmetic encoding，但是可以用非二進位來壓縮)。

壓縮流程:

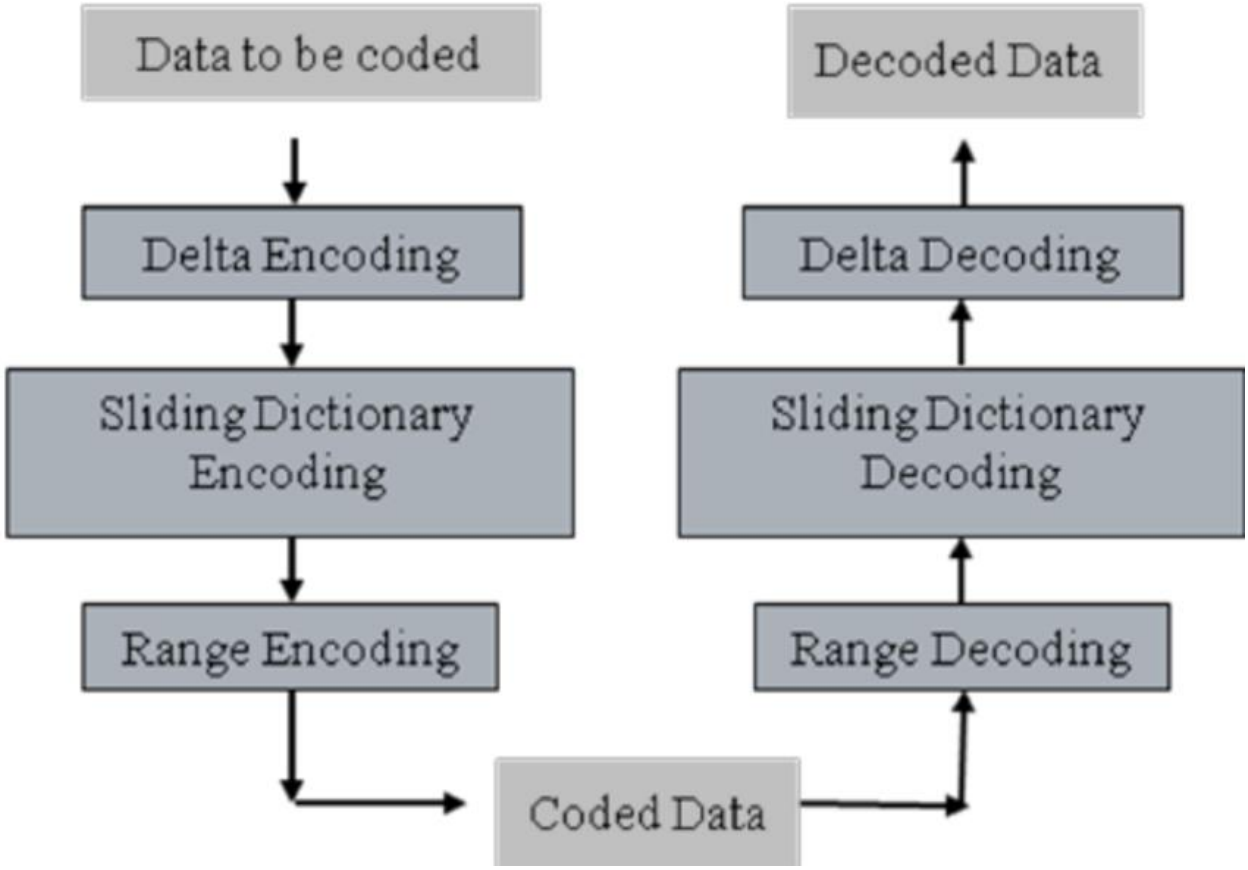

二、Lzma 的壓縮後格式簡介:

.lzma 檔案就是被 lzma 壓縮後的資料格式，它包含了兩個部分，header 以及 LZMA Compressed Data，如下圖。

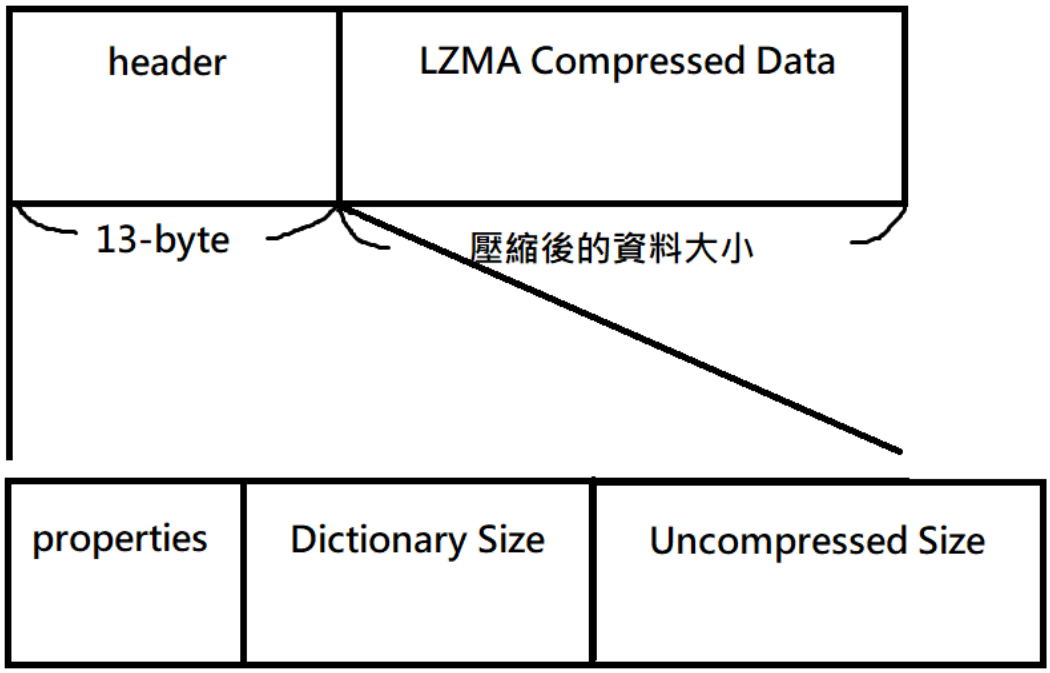

(一)、header 內部構造:

1. Properties:

Properties 內部由三個變數所組成:

(1) lc: literal context 的 bits 數量，範圍是[0, 8]

之前的 byte 當中有多少是 1 的 bit 會拿來當作 context(前後文)。

(2) lp: literal position 的 bits 數量，範圍是[0, 4]
(3) pb: postion 的 bits 數量，範圍是[0, 4]

最後用這個式子把以上三個變數 encode:

Properties = (pb * 5 + lp) * 9 + lc

Decode 就會用以下的 sudo code 來達成:

```
pb = properties / (9 * 5);
properties -= pb * 9 * 5;
lp = properties / 9;
lc = properties - lp * 9;
```

2. Dictionary Size:
用 unsigned 32-bit little endian integer 來儲存字典大小，所以總共是 4 個 byte。
但是為了提供好的移植性(不同硬體)，應該只用 2^n 或者是 2^n+2^(n-1)這兩種 size。

3. Uncompressed Size:
未壓縮大小是用 unsigned 64-bit little endian integer 來儲存的。

比較特別的是，如果 64 個 bit 都是 1 的話，代表未壓縮大小是未知的。

(二)、LZMA Compressed Data
經由 LZMA 壓縮過後的資料會存放在這個區塊。
壓縮後的形式為 bit stream，並且用 adaptive binary range coder 做 encode，而 bit stream 會被劃分成很多 packets，packets 的形式如下:

packed code (bit sequence)	packet name	packet description
0 + byteCode	LIT	A single byte encoded using an adaptive binary range coder.
1+0 + len + dist	MATCH	A typical LZ77 sequence describing sequence length and distance.
1+1+0+0	SHORTREP	A one-byte LZ77 sequence. Distance is equal to the last used LZ77 distance.
1+1+0+1 + len	LONGREP[0]	An LZ77 sequence. Distance is equal to the last used LZ77 distance.
1+1+1+0 + len	LONGREP[1]	An LZ77 sequence. Distance is equal to the second last used LZ77 distance.
1+1+1+1+0 + len	LONGREP[2]	An LZ77 sequence. Distance is equal to the third last used LZ77 distance.
1+1+1+1+1 + len	LONGREP[3]	An LZ77 sequence. Distance is equal to the fourth last used LZ77 distance.

1. LIT: literal，代表單獨的 byte 並且用 adaptive binary range coder encode，新出現的 character。

2. MATCH: 標準的 LZ77 格式，有長度(在 window 找到 look ahead buffer 的 code 的長度)還有距離(look ahead buffer 的 code 出現在 window 的哪裡)

3. SHORTREP: 一個 byte 的 LZ77 序列，距離等同於上一個 LZ77 使用的距離

4. LONGREP[n]: 一個 LZ77 的序列，並且距離等同於上 n 個 LZ77 的距離

長度的 encode 用以下的表格:

Length code (bit sequence)	Description
0+ 3 bits	The length encoded using 3 bits, gives the lengths range from 2 to 9.
1+0+ 3 bits	The length encoded using 3 bits, gives the lengths range from 10 to 17.
1+1+ 8 bits	The length encoded using 8 bits, gives the lengths range from 18 to 273.

Distance 用以下表格編碼:

6-bit distance slot	Highest 2 bits	Fixed 0.5 probability bits	Context encoded bits
0	00	0	0
1	01	0	0
2	10	0	0
3	11	0	0
4	10	0	1
5	11	0	1
6	10	0	2
7	11	0	2
8	10	0	3
9	11	0	3
10	10	0	4
11	11	0	4
12	10	0	5
13	11	0	5
14–62 (even)	10	((slot / 2) − 5)	4
15–63 (odd)	11	(((slot − 1) / 2) − 5)	4

每一個 distance 都會用 6-bit distance slot 作為起始，6-bit distance slot 存的數字就是後面會再接多少 bit 的意思。

三、lzma、jpeg 與先壓縮成 jpeg 再放到 lzma 壓縮 Lena.raw 的比較

(一)、方法

Jpeg 壓縮直接用 irfanview 把 Lena.raw 存檔成 jpeg 檔案並且把畫質調到 100(最高)，png 壓縮也是用 irfanview，而 lzma 壓縮採用的是 python 預設的套件”lzma”，最後再將兩者的檔案大小計算出來。

(二)、數據比較

壓縮後檔案大小

(1) jpeg: 154679 bytes (有損)

(2) png: 224248 bytes

(3) lzma: 180133 bytes (無損)

(4) jpeg 再做 lzma 並存成.lzma 格式: 156012 bytes

(5) jpeg 再做 lzma 並存成.7z 格式: 156138 bytes

(5) png 再做 lzma 並存成.lzma 格式: 223698 bytes

(6) png 再做 lzma 並存成.7z 格式: 223853 bytes

(三)、結果

得到的結果是 jpeg 壓縮完之後再用 lzma 壓縮反而讓檔案越壓縮越大，而 png 壓縮完之後再用 lzma 壓縮則能降低少許檔案大小。

而存成.7z 格式後檔案變大是因為標頭檔變大而導致壓縮完後的檔案變大了。

Code:

用 python lzma 套件壓縮圖片

https://github.com/Louislar/DataCompression_finalReport

參考:

[1]: https://dev.twsiyuan.com/2018/06/how-to-compress-and-decompress-gamesaves-in-unity.html

[2]: http://html.rhhz.net/BJHKHTDXXBZRB/20150302.htm#R-4

[3]: https://gautiersblog.blogspot.com/2016/08/lzma-compression.html